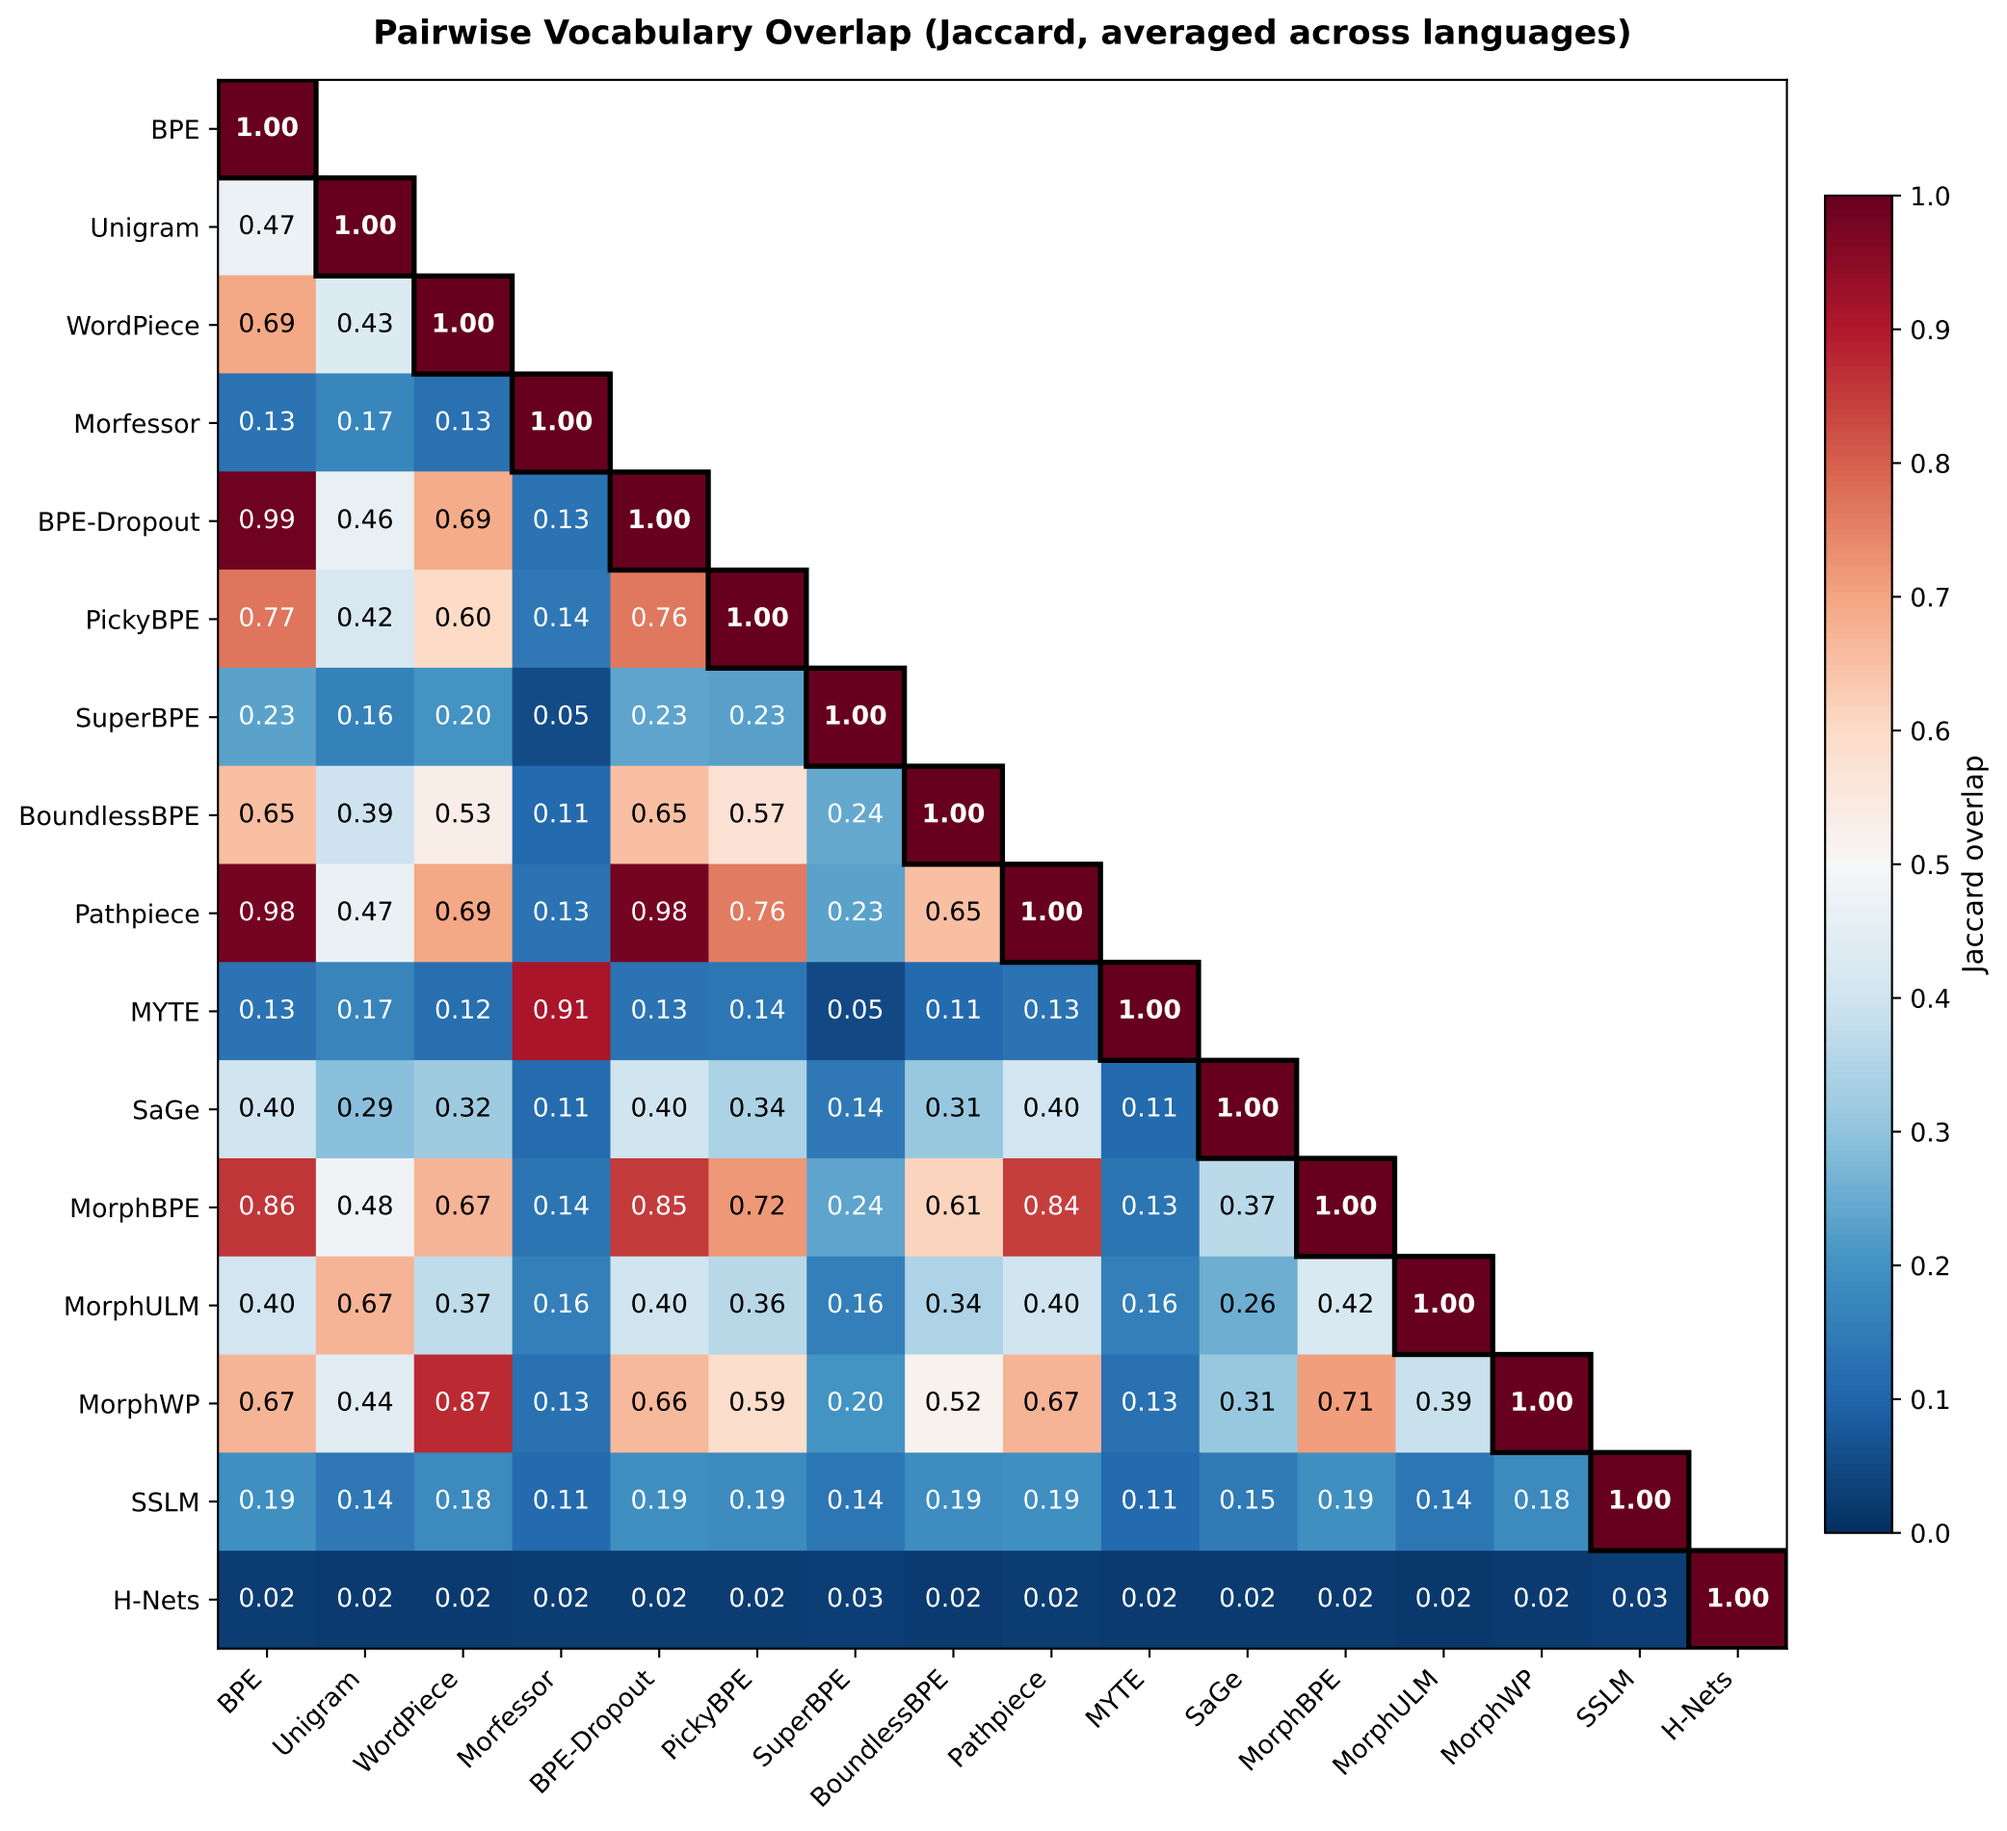
Pairwise Vocabulary Overlap (Jaccard, averaged across languages)
BPE 1.00
Unigram 0.47 1.00
WordPiece 0.69 0.43 1.00
Morfessor 0.13 0.17 0.13 1.00
BPE-Dropout 0.99 0.46 0.69 0.13 1.00
PickyBPE 0.77 0.42 0.60 0.14 0.76 1.00
SuperBPE 0.23 0.16 0.20 0.05 0.23 0.23 1.00
BoundlessBPE 0.65 0.39 0.53 0.11 0.65 0.57 0.24 1.00
Pathpiece 0.98 0.47 0.69 0.13 0.98 0.76 0.23 0.65 1.00
MYTE 0.13 0.17 0.12 0.91 0.13 0.14 0.05 0.11 0.13 1.00
SaGe 0.40 0.29 0.32 0.11 0.40 0.34 0.14 0.31 0.40 0.11 1.00
MorphBPE 0.86 0.48 0.67 0.14 0.85 0.72 0.24 0.61 0.84 0.13 0.37 1.00
MorphULM 0.40 0.67 0.37 0.16 0.40 0.36 0.16 0.34 0.40 0.16 0.26 0.42 1.00
MorphWP 0.67 0.44 0.87 0.13 0.66 0.59 0.20 0.52 0.67 0.13 0.31 0.71 0.39 1.00
SSLM 0.19 0.14 0.18 0.11 0.19 0.19 0.14 0.19 0.19 0.11 0.15 0.19 0.14 0.18 1.00
H-Nets 0.02 0.02 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.02 0.03 1.00
BPE
Unigram
WordPiece
Morfessor
BPE-Dropout
PickyBPE
SuperBPE
BoundlessBPE
Pathpiece
MYTE
SaGe
MorphBPE
MorphULM
MorphWP
SSLM
H-Nets
Jaccard overlap
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0.0